



Τμήμα Ηλεκτρολόγων Μηχανικών και Τεχνολογίας Υπολογιστών

Μάθημα: Ευφυής Έλεγχος

Safe Mobile Robot Button Navigation στο περιβάλλον SafetyRacecarButton2-v0

Ομάδα:

Παπαδόπουλος Μάριος Ιωάννης – 1092834

Θεολόγος Φίλιππος Νεόφυτος - 1092633

Περίληψη

Η παρούσα εργασία εξετάζει τον σχεδιασμό ενός ελεγκτή ασφαλούς πλοήγησης για το περιβάλλον SafetyRacecarButton2-v0 του Safety-Gymnasium. Ο πράκτορας είναι ένα όχημα τύπου racecar, το οποίο πρέπει να εντοπίζει και να πατά το σωστό κουμπί, αποφεύγοντας κινδύνους, gremlins και λανθασμένα κουμπιά. Η δυσκολία του προβλήματος προκύπτει από τη συνεχή δράση ταχύτητας-διεύθυνσης, τη μερική πληροφορία που λαμβάνει ο agent από τα lidars και την ανάγκη ταυτόχρονης μεγιστοποίησης της ανταμοιβής και ελαχιστοποίησης του κόστους ασφαλείας.

Στην εργασία συγκρίνονται τέσσερις κατηγορίες ελεγκτών:

1. **Τυχαία πολιτική (random baseline)**, η οποία επιλέγει ενέργειες χωρίς γνώση της κατάστασης του περιβάλλοντος και χρησιμοποιείται ως βασικό σημείο αναφοράς.
2. **Rule-based reactive controller**, ο οποίος επιλέγει δυναμικά μεταξύ προσέγγισης στόχου, αποφυγής εμποδίων, ανάκαμψης με οπισθοπορεία και αναζήτησης στόχου, ανάλογα με τις παρατηρήσεις του περιβάλλοντος. Η επιλογή της συμπεριφοράς βασίζεται κυρίως στις μετρήσεις lidar και στην εκτιμώμενη κατεύθυνση του σωστού κουμπιού. Για κάθε κατάσταση, ο ελεγκτής παράγει προκαθορισμένες εντολές ταχύτητας και διεύθυνσης.
3. **Learning-based ελεγκτής TD3**, βασισμένος στον αλγόριθμο Twin Delayed Deep Deterministic Policy Gradient. Πριν δοθούν στο νευρωνικό δίκτυο, οι παρατηρήσεις του περιβάλλοντος κανονικοποιούνται σε κοινή αριθμητική κλίμακα. Έτσι, μετρήσεις διαφορετικού εύρους και φυσικής σημασίας, όπως lidar, ταχύτητες και δεδομένα αισθητήρων, δεν επηρεάζουν δυσανάλογα τη διαδικασία εκπαίδευσης.
 - Ο actor του TD3 παράγει δύο κανονικοποιημένες εντολές: μία για την ταχύτητα του οχήματος και μία για τη γωνία διεύθυνσης. Οι εντολές αυτές μετατρέπονται στη συνέχεια στα πραγματικά επιτρεπτά όρια του racecar πριν εφαρμοστούν στο περιβάλλον. Με αυτόν τον τρόπο, η πολιτική μπορεί να εκπαιδευτεί σε σταθερότερη αριθμητική κλίμακα, ενώ οι τελικές ενέργειες παραμένουν συμβατές με τους φυσικούς περιορισμούς του οχήματος.
 - Η εκπαίδευση του TD3 βασίζεται σε εμπειρίες που αποθηκεύονται σε replay buffer. Επιπλέον, χρησιμοποιούνται δύο critic networks για τη μείωση της υπερεκτίμησης της αξίας των ενεργειών, ενώ ο actor ενημερώνεται με μικρότερη συχνότητα. Η πολιτική εκπαιδεύεται ώστε να μεγιστοποιεί τη συνολική ανταμοιβή και, στις safety-aware παραλλαγές, η συνάρτηση εκπαίδευσης περιλαμβάνει επιπλέον ποινή ανάλογη με το κόστος μη ασφαλών ενεργειών.

4. Learning based ελεγκτής SAC, ένας off-policy actor-critic αλγόριθμος κατάλληλος για προβλήματα συνεχούς χώρου δράσεων (continuous action spaces). Σε αντίθεση με τον TD3, ο SAC χρησιμοποιεί στοχαστική πολιτική, επιτρέποντας στον agent να δειγματοληπτεί διαφορετικές ενέργειες από μία Gaussian κατανομή αντί να επιλέγει πάντα μία μοναδική ντετερμινιστική ενέργεια.

Η βασική ιδέα του SAC είναι η ταυτόχρονη μεγιστοποίηση της συνολικής ανταμοιβής και της εντροπίας (entropy) της πολιτικής. Η μεγιστοποίηση της εντροπίας ενθαρρύνει την εξερεύνηση του περιβάλλοντος και μειώνει την πιθανότητα πρόωρης σύγκλισης σε μη βέλτιστες πολιτικές.

Όπως και ο TD3, ο SAC χρησιμοποιεί δύο ανεξάρτητα Critic δίκτυα (Twin Critics), replay buffer και target networks για μεγαλύτερη σταθερότητα κατά την εκπαίδευση. Ωστόσο, αντί να χρησιμοποιεί εξωτερικό θόρυβο για exploration, η εξερεύνηση προκύπτει φυσικά από τη στοχαστική πολιτική του Actor. Επιπλέον, ο αλγόριθμος προσαρμόζει αυτόματα την παράμετρο θερμοκρασίας α , η οποία ελέγχει την ισορροπία μεταξύ exploration και exploitation.

Περιγραφή του περιβάλλοντος

Στοιχείο	Περιγραφή
Environment	Safety-Gymnasium: SafetyRacecarButton2-v0
Agent	Racecar, με έλεγχο rear-wheel velocity και front-wheel steering.
Action	$a_t = [v_t, \delta_t]$, όπου v_t είναι η ζητούμενη ταχύτητα και δ_t η γωνία διεύθυνσης.
Observation	Διάνυσμα 76 διαστάσεων: accelerometer (3), velocimeter (3), gyro (3), magnetometer (3), και τέσσερις lidar ομάδες των 16 bins.
Lidars	buttons_lidar, goal_lidar, hazards_lidar, gremlins_lidar.
Return	Πρόοδος προς τον σωστό στόχο και αλληλεπίδραση με το σωστό κουμπί. Reward Distance: $r_\tau = (D_{last} - D_{now})\beta$
Cost	Κίνδυνοι, επαφές με gremlins ή/και λανθασμένη αλληλεπίδραση με κουμπιά, όπως ορίζει το benchmark.

Στοιχείο	Περιγραφή
Horizon	Το benchmark ορίζει ως προεπιλεγμένο μέγιστο ορίζοντα τα 1.000 timesteps ανά επεισόδιο. Ένα επεισόδιο ολοκληρώνεται νωρίτερα μόνο εφόσον ορίσουμε κάποια συνθήκη τερματισμού του περιβάλλοντος όπως το πάτημα του σωστού κουμπιού διαφορετικά, τερματίζεται λόγω του χρονικού ορίου.

Η βασική χρονική ακολουθία είναι: παρατήρηση o_t , επιλογή δράσης a_t , μετάβαση στο περιβάλλον και επιστροφή (o_{t+1} , r_t , c_t , *terminated*, *truncated*, *info*). Το κόστος c_t καταγράφεται ξεχωριστά από την ανταμοιβή. Με αυτόν τον τρόπο μπορεί να αξιολογηθεί αν μία πολιτική βελτιώνει πράγματι το task ή απλώς επισπεύδει τη γρήγορη πρόοδο εμπίπτοντας σε επαναλαμβανόμενες παραβιάσεις ασφαλείας.

Μεθοδολογία

Συνολική στρατηγική σύγκρισης

Η εργασία συγκρίνει τέσσερις βασικές κατηγορίες ελεγκτών, ώστε η αξιολόγηση να μη βασίζεται σε μία μόνο πολιτική. Η τυχαία πολιτική χρησιμοποιείται ως sanity baseline, ελέγχοντας ότι τυχόν επιτυχίες δεν οφείλονται σε τυχαία επιλογή ενεργειών. Ο rule-based reactive controller αποτελεί ένα απλό και επεξηγήσιμο baseline, βασισμένο σε προκαθορισμένους κανόνες πλοήγησης και αποφυγής εμποδίων.

Οι δύο learning-based προσεγγίσεις είναι οι αλγόριθμοι TD3 και SAC. Και οι δύο μπορούν να μάθουν σύνθετες συσχετίσεις μεταξύ των μετρήσεων lidar, της δυναμικής του racetrack και της κατάλληλης επιλογής δράσης. Ο TD3 χρησιμοποιεί ντετερμινιστική actor-critic πολιτική και εξετάζεται τόσο χωρίς, όσο και με safety-aware όρο κόστους. Αντίθετα, ο SAC χρησιμοποιεί στοχαστική πολιτική και ενθαρρύνει την εξερεύνηση μέσω ενός όρου εντροπίας, γεγονός που μπορεί να είναι χρήσιμο σε περιβάλλοντα με πολλαπλές πιθανές διαδρομές προς τον στόχο.

Μέθοδος	Ρόλος	Χαρακτηριστικά	Αναμενόμενη συμπεριφορά
Random policy	Sanity baseline	Τυχαίο speed και steering εντός action space.	Δεν αναμένεται συστηματική επίλυση της εργασίας.
Rule-based reactive controller	Απλό/ερμηνεύσιμο baseline	Κατεύθυνση προς goal lidar, αποφυγή obstacles, modes: SEEK/AVOID/RECOVERY/SEARCH.	Καλή άμεση αντίδραση αλλά περιορισμένη πρόβλεψη και πιθανές ταλαντώσεις ή τοπικά αδιέξοδα

Μέθοδος	Ρόλος	Χαρακτηριστικά	Αναμενόμενη συμπεριφορά
TD3, $\lambda = 0$	Nominal RL baseline	Συνεχής actor-critic πολιτική, target networks, TD3 stabilization.	Έμφαση στη μεγιστοποίηση του reward χωρίς ποινή για το safety cost.
TD3, $\lambda > 0$	Safety-aware competing method	Ίδια TD3 αρχιτεκτονική, αλλά εκπαίδευση με $r - \lambda c$.	Στόχος μικρότερο cost με πιθανό τίμημα σε reward/ταχύτητα μάθησης.
SAC, $\lambda = 0$	Nominal RL baseline	Στοχαστική actor-critic πολιτική με entropy regularization, replay buffer και twin critics. Εκπαίδευση μόνο με το reward.	Η στοχαστική πολιτική ενισχύει την εξερεύνηση και την εύρεση εναλλακτικών στρατηγικών, με έμφαση στη μεγιστοποίηση του reward.
SAC, $\lambda > 0$	Safety-aware competing method	Ίδια αρχιτεκτονική SAC, αλλά εκπαίδευση με $r - \lambda c$.	Συνδυάζει την αυξημένη εξερεύνηση του SAC με αποφυγή μη ασφαλών ενεργειών μέσω της ποινής κόστους, επιδιώκοντας καλύτερο trade-off μεταξύ reward και safety.

Rule based controller

Ως μη μαθησιακό baseline υλοποιήθηκε ένας rule-based reactive controller για το περιβάλλον SafetyRacecarButton2-v0. Ο controller δεν χρησιμοποιεί εκπαίδευση. Αντίθετα, σε κάθε χρονικό βήμα λαμβάνει απόφαση από την τρέχουσα παρατήρηση lidar και από μια μικρή εσωτερική μνήμη, δηλαδή η τελευταία πλευρά στην οποία είχε εντοπιστεί ο στόχος και η κατάσταση ανάκαμψης.

Η βασική ιδέα είναι να μετατραπούν οι 16 κατευθυντικές lidar μετρήσεις σε διανύσματα κατεύθυνσης. Από το goal_lidar εκτιμάται η πλευρά και η σχετική γωνία του σωστού στόχου, ενώ από το buttons_lidar δημιουργείται ένα σήμα που αντιπροσωπεύει πιθανή παρουσία λανθασμένων buttons. Έτσι, ο controller μπορεί να κινηθεί προς τον στόχο όταν η διαδρομή είναι σχετικά καθαρή ή να στρίψει μακριά από ανεπιθύμητα buttons όταν αυτά ανιχνεύονται στη μπροστινή περιοχή.

Η τελική δράση έχει τη μορφή:

$$a_t = [v_t \quad \delta_t]^T$$

όπου v_t είναι η εντολή ταχύτητας των πίσω τροχών και δ_t η εντολή steering. Η γωνία steering περιορίζεται στο φυσικό διάστημα $[-\delta_{\max}, \delta_{\max}]$, με $\delta_{\max} = 0.785$ rad.

Ο controller οργανώνεται ως finite-state machine με πέντε λειτουργίες. Η επιλογή τους γίνεται με σειρά προτεραιότητας, ώστε οι καταστάσεις ασφαλείας και ανάκαμψης να υπερισχύουν της απλής κίνησης προς τον στόχο.

Mode	Συνθήκη ενεργοποίησης	Ενέργεια
RECOVERY	Πολύ υψηλή ένταση λανθασμένου-button σήματος ακριβώς μπροστά ή συνέχιση ήδη ενεργής recovery διαδικασίας.	Οπισθοπορεία με σταθερή εντολή steering.
REVERSE_TO_GOAL	Ο στόχος είναι ορατός αλλά βρίσκεται αρκετά πίσω από το όχημα.	Οπισθοπορεία με steering προσαρμοσμένο στο σύστημα αναφοράς της όπισθεν.
AVOID	Εντοπίζεται σημαντικός κίνδυνος στο ευρύτερο εμπρόσθιο τόξο lidar.	Μειωμένη εμπρόσθια ταχύτητα και steering που συνδυάζει έλξη προς τον στόχο και απομάκρυνση από λανθασμένα buttons.
SEEK_GOAL	Ο στόχος είναι επαρκώς ορατός και δεν υπάρχει σημαντικός εμπρόσθιος κίνδυνος.	Μέγιστη εμπρόσθια ταχύτητα και steering προς τη γωνία του στόχου.
SEARCH	Το σήμα του στόχου είναι πολύ ασθενές ή δεν είναι ορατό.	Χαμηλή εμπρόσθια ταχύτητα και ήπια στροφή προς την τελευταία αξιόπιστη πλευρά του στόχου.

Στη λειτουργία SEEK_GOAL, η κατεύθυνση του στόχου υπολογίζεται από το διανυσματικό άθροισμα των goal-lidar μετρήσεων. Η αντίστοιχη σχετική γωνία χρησιμοποιείται απευθείας για την επιλογή steering. Όταν ενεργοποιείται η λειτουργία AVOID, σχηματίζεται ένα διάνυσμα αποφυγής από το σήμα των λανθασμένων buttons και αφαιρείται από το διάνυσμα του στόχου. Με αυτόν τον τρόπο, ο controller επιδιώκει να προσεγγίσει τον στόχο χωρίς να κατευθύνεται ευθέως προς πιθανώς λανθασμένα buttons.

Ιδιαίτερη σημασία έχει η λειτουργία RECOVERY. Όταν ο εμπρόσθιος κίνδυνος ξεπεράσει το προκαθορισμένο κατώφλι, ο controller εισέρχεται σε οπισθοπορεία και διατηρεί τη συγκεκριμένη εντολή για έναν ελάχιστο αριθμό βημάτων. Αυτό αποτρέπει γρήγορες εναλλαγές μεταξύ εμπρόσθιας και οπίσθιας κίνησης, οι οποίες θα μπορούσαν να οδηγήσουν σε ταλαντώσεις ή παγίδευση κοντά σε εμπόδια. Μετά την ολοκλήρωση του recovery εφαρμόζεται μικρό cooldown, ώστε να μην επανενεργοποιηθεί αμέσως η ίδια συμπεριφορά.

Στις ρυθμίσεις που χρησιμοποιήθηκαν, η μέγιστη εμπρόσθια ταχύτητα είναι 12, η ελάχιστη ταχύτητα αναζήτησης είναι 2, η ταχύτητα αποφυγής είναι ίση με 0.6 της μέγιστης ταχύτητας, η ταχύτητα recovery είναι -8 και η ταχύτητα

REVERSE_TO_GOAL είναι -10 . Η λειτουργία αποφυγής ενεργοποιείται όταν το εμπρόσθιο σήμα κινδύνου υπερβεί το 0.35 , ενώ η λειτουργία recovery ενεργοποιείται σε υψηλότερο κατώφλι 0.85 .

Ο rule-based controller αποτελεί χρήσιμο baseline επειδή είναι πλήρως ερμηνεύσιμος: κάθε δράση μπορεί να αιτιολογηθεί από τη λειτουργία που ήταν ενεργή και από τα αντίστοιχα lidar χαρακτηριστικά. Παράλληλα, παρουσιάζει περιορισμούς. Δεν μαθαίνει από προηγούμενη εμπειρία, δεν προσαρμόζει αυτόματα τα thresholds του και στην παρούσα υλοποίηση αξιοποιεί μόνο τα buttons_lidar και goal_lidar. Επομένως, δεν εκμεταλλεύεται άμεσα τα lidar σήματα hazards και gremlins, σε αντίθεση με τον TD3 agent, ο οποίος δέχεται ολόκληρη την παρατήρηση και μπορεί θεωρητικά να μάθει πιο σύνθετες στρατηγικές αποφυγής.

TD3

Για την learning-based προσέγγιση χρησιμοποιήθηκε ο αλγόριθμος Twin Delayed Deep Deterministic Policy Gradient (TD3), ο οποίος είναι κατάλληλος για προβλήματα με συνεχές action space. Στο συγκεκριμένο περιβάλλον, η δράση του racecar γράφεται ως

$$a_t = [v_t \delta_t]$$

όπου v_t είναι η εντολή ταχύτητας των πίσω τροχών και δ_t η γωνία διεύθυνσης των εμπρός τροχών.

Ο TD3 χρησιμοποιεί έναν actor και δύο critics. Ο actor υλοποιεί μια ντετερμινιστική πολιτική:

$$\tilde{a}_t = \tanh\left(f_{\theta_{\pi}}(\tilde{o}_t)\right), \tilde{a}_t \in [-1, 1]^2$$

όπου $\tilde{o}_t$ είναι η κανονικοποιημένη παρατήρηση $\tilde{a}_t$ η κανονικοποιημένη δράση. Η έξοδος του actor μετατρέπεται στη φυσική κλίμακα δράσης που χρησιμοποιεί το racecar ως εξής:

$$a_t = b + s \odot \tilde{a}_t, \quad b = \frac{amax+amin}{2}, \quad s = \frac{amax-amin}{2}$$

Τα $amax$ και $amin$ είναι τα ενεργά φυσικά όρια ταχύτητας και steering που χρησιμοποιούνται σε κάθε πείραμα.

Οι δύο critics προσεγγίζουν ανεξάρτητα τις action-value Functions:

$$Q_{\phi 1}(\tilde{o}_t, a_t), Q_{\phi 2}(\tilde{o}_t, a_t),$$

Η χρήση δύο critics αντιμετωπίζει την τάση των actor-critic μεθόδων να υπερεκτιμούν τις Q-values. Για την κατασκευή του TD target χρησιμοποιείται η μικρότερη από τις δύο εκτιμήσεις των target critics:

$$y_t = r_t^{train} + \gamma(1 - d_t) \min\{Q_{\varphi_1}(\tilde{o}_{t+1}, a_{t+1}^{target}), Q_{\varphi_2}(\tilde{o}_{t+1}, a_{t+1}^{target})\}$$

Το d_t είναι είναι δυαδικός δείκτης τερματισμού της μετάβασης: λαμβάνει τιμή 1 όταν η μετάβαση οδηγεί σε πραγματικό τερματισμό του επεισοδίου και 0 διαφορετικά.

Η target action δεν παράγεται ακριβώς από τον target actor, αλλά περιλαμβάνει μικρή θορυβώδη διαταραχή:

$$\tilde{a}_{t+1}^{tar} = clip(tanh(f_{\tilde{\theta}}(\tilde{o}_{t+1})) + \epsilon, -1, 1), \quad \epsilon: \text{μία πολύ μικρή τυχαία μεταβολή}$$

Η διαταραχή αυτή υλοποιεί το target policy smoothing. Ο σκοπός της είναι οι critics να μη μαθαίνουν ότι η αξία μιας κατάστασης εξαρτάται από μία απολύτως ενέργεια, αλλά να αξιολογούν ένα μικρό σύνολο παρόμοιων ενεργειών.

Οι critics εκπαιδεύονται ελαχιστοποιώντας το μέσο τετραγωνικό σφάλμα:

$$L_{Q_i} = \frac{1}{B} \sum_{\{k=1\}}^B (Q_{\varphi_i}(\tilde{o}_k, a_k) - y_k)^2, \quad i \in \{1, 2\}$$

όπου B είναι το μέγεθος του batch. Ο actor ενημερώνεται αραιότερα από τους critics, κάθε POLICY DELAY critic updates, με στόχο να μεγιστοποιεί την αξία που προβλέπει ο πρώτος critic:

$$L_{\pi} = -\frac{1}{B} \sum_{\{k=1\}}^B (Q_{\varphi_1}(\tilde{o}_k, \pi_{\theta}(\tilde{o}_k)))$$

Η καθυστερημένη ενημέρωση του actor επιτρέπει στους critics να σταθεροποιηθούν πριν ο actor μετακινηθεί προς δράσεις που φαίνονται καλύτερες. Τέλος, τα target δίκτυα ενημερώνονται αργά μέσω Polyak averaging:

$$\bar{\varphi} \rightarrow \tau\varphi + (1 - \tau)\bar{\varphi}$$

$$\bar{\theta} \rightarrow \tau\theta + (1 - \tau)\bar{\theta}$$

Με μικρό τ (tau) τα target δίκτυα μεταβάλλονται ομαλά και παρέχουν σταθερότερους Bellman targets.

Πίνακας ρυθμίσεων TD3 run

Παράμετρος	Σύντομη λειτουργία / επίδραση
ENV_ID	Επιλέγει το benchmark περιβάλλον.
RUN_NAME	Αναγνωριστικό για φακέλους logs, checkpoints και TensorBoard· διαχωρίζει αυτό το run από τα υπόλοιπα.
SEED	Αρχικοποιεί τις ψευδοτυχαίες γεννήτριες, βελτιώνοντας την αναπαραγωγικότητα του πειράματος.

GOAL_TERMINATION	Το επεισόδιο τερματίζεται όταν επιτευχθεί το σωστό goal button, αντί να συνεχίζει άσκοπα μέχρι το horizon.
LOAD_FROM	Με "branch" δημιουργείται νέο run βασιζόμενο σε προηγούμενο, με τυχαία αρχικοποίηση buffer, με "latest" συνεχίζει το run από εκεί που σταμάτησε, με "none" δημιουργείται νέο ανεξάρτητο run.
SOURCE_RUN_NAME / SOURCE_POLICY_FILE	Ρυθμίσεις που θα χρησιμοποιηθούν μόνο σε resume. Με LOAD_FROM = none δεν επηρεάζουν το συγκεκριμένο run.
ACTION_REPEAT / UPDATES_PER_ACTION_DECISION	Κάθε action εκτελείται για δύο environment steps. Γίνονται δύο updates ανά νέα απόφαση.
TOTAL_STEPS	Συνολικό training budget. Μεγαλύτερο budget επιτρέπει περισσότερη εξερεύνηση και βελτίωση, με αυξημένο χρόνο εκπαίδευσης.
RANDOM_STEPS	Αρχική συλλογή τυχαίων actions για ποικιλία transitions και ασφαλέστερα πρώτα critic updates.
POLICY_REFILL_STEPS	Συλλέγει transitions από φορτωμένη πολιτική μετά από resume χωρίς replay buffer. Δεν ενεργοποιείται στο baseline.
EXPLORATION_NOISE	Θόρυβος στις actions του actor κατά τη συλλογή εμπειρίας· αυξάνει εξερεύνηση, αλλά υπερβολική τιμή αυξάνει αστάθεια/συγκρούσεις.
BUFFER_SIZE	Μέγιστη χωρητικότητα replay buffer. Μεγάλο off-policy σύνολο με ποικιλία εμπειριών· οι παλιότερες αντικαθίστανται κυκλικά.
BATCH_SIZE	Transitions ανά update. Μειώνει τον θόρυβο του gradient χωρίς υπερβολική χρήση μνήμης.
OBS_NORMALIZER_CLIP	Περιορίζει κάθε running-normalized observation στο [-5, 5], ώστε ακραίες τιμές να μη κυριαρχούν στα gradients.
EVALUATE EVERY / EVALUATION_EPISODES	Περιοδική αξιολόγηση. Ο μέσος όρος 10 επεισοδίων μειώνει τη μεταβλητότητα από τυχαίες αρχικοποιήσεις.
SAVE_FULL_CHECKPOINT_EVERY	Αποθηκεύει πλήρες checkpoint για ασφαλές resume και σύγκριση ενδιάμεσων πολιτικών.
USE_TENSORBOARD / TENSORBOARD_EVERY	Καταγράφει reward, cost, losses, actions και diagnostics σε συχνότητα επαρκή για παρακολούθηση της εκπαίδευσης.
COST_PENALTY / BEST_SELECTION_COST_WEIGHT	Nominal TD3: το training objective και η επιλογή checkpoint δεν περιλαμβάνουν άμεση ποινή safety cost. Το cost συνεχίζει να καταγράφεται.
LEARNING_RATE	Μέγεθος gradient step για actor και critics. Μικρή τιμή για ομαλότερες ενημερώσεις σε ευαίσθητο continuous-control πρόβλημα.
DISCOUNT (γ)	Βάρος μελλοντικής ανταμοιβής στο Bellman target. Ευνοεί μακροπρόθεσμη πρόοδο προς το σωστό button.
TAU (τ)	Ρυθμός Polyak averaging: τα target δίκτυα διατηρούν 99.5% της προηγούμενης τιμής και λαμβάνουν 0.5% από τα κύρια δίκτυα.
POLICY_NOISE / NOISE_CLIP	Gaussian θόρυβος και όριο για target-policy smoothing. Οι critics αξιολογούν παρεμφερή actions και αποφεύγονται μεγάλες μη ρεαλιστικές διαταραχές.
POLICY_DELAY	Ο actor και τα target networks ενημερώνονται κάθε δύο critic updates, ώστε οι critics να σταθεροποιούνται πριν αλλάξει η πολιτική.

Κανονικοποίηση παρατηρήσεων και δράσεων

Οι παρατηρήσεις περιλαμβάνουν διαφορετικούς τύπους μεγεθών, όπως lidar, επιταχύνσεις, γωνιακές ταχύτητες και γραμμικές ταχύτητες. Οι ποσότητες αυτές δεν έχουν όλες την ίδια κλίμακα ή την ίδια στατιστική κατανομή. Για τον λόγο αυτό διακρίνουμε δύο διαφορετικές περιπτώσεις κανονικοποίησης.

Κανονικοποίηση με γνωστά bounds

Όταν μία μεταβλητή έχει γνωστά, σταθερά και ουσιαστικά φυσικά όρια, $[l_j, u_j]$ μπορεί να μεταφερθεί άμεσα στο διάστημα $[-1, 1]$:

$$\tilde{o}_j^{bounds} = 2 * \frac{o_j - l_j}{u_j - l_j} - 1$$

Η μέθοδος αυτή είναι κατάλληλη όταν τα bounds είναι εγγυημένα από το περιβάλλον και έχουν σαφή φυσική σημασία. Για παράδειγμα, εφαρμόζεται φυσικά στις δράσεις του `racetrack`, επειδή τα επιτρεπτά όρια ταχύτητας και `steering` είναι γνωστά πριν αρχίσει η εκπαίδευση. Δεν απαιτείται εκτίμηση στατιστικών από δεδομένα και ο μετασχηματισμός είναι διαθέσιμος από το πρώτο βήμα.

Η αντίστροφη μετατροπή από κανονικοποιημένη δράση στη φυσική δράση είναι:

$$a_{t,j} = a_{min,j} + \frac{\tilde{a}_{t,j} + 1}{2} (a_{max,j} - a_{min,j})$$

Η κανονικοποίηση βάσει bounds διατηρεί τη σημασία των φυσικών ορίων. Ωστόσο, δεν εγγυάται ότι η είσοδος του δικτύου θα έχει μηδενικό μέσο ή μοναδιαία διασπορά, επειδή αυτό εξαρτάται από το πόσο συχνά επισκέπτεται ο agent κάθε περιοχή του state space.

Online Z-score normalization με Running mean και variance

Για τις διαστάσεις χωρίς αξιόπιστα πεπερασμένα bounds εφαρμόζεται online z-score normalization με running mean και variance, ακολουθούμενη από clipping. Αυτό συμβαίνει για τα car-sensor χαρακτηριστικά που το Gym δηλώνει χωρίς πεπερασμένα όρια, όπως accelerometer, velocimeter, gyro και magnetometer τα οποία βρίσκονται με δυναμικό τρόπο. Οι running στατιστικές ενημερώνονται μόνο από νέες παρατηρήσεις που συλλέγονται κατά την εκπαίδευση, συμπεριλαμβανομένων των warm-up και replay buffer refill φάσεων. Το replay buffer αποθηκεύει raw observations και τα sampled batches κανονικοποιούνται με τις τρέχουσες στατιστικές χωρίς να τις ενημερώνουν. Κατά την αξιολόγηση και την τελική εκτέλεση, οι στατιστικές παραμένουν παγωμένες και φορτώνονται από το

checkpoint, με αποτέλεσμα η αξιολόγηση να είναι reproducible και να μην επηρεάζεται από πληροφορία που συλλέγεται κατά τα evaluation episodes.

$$\tilde{o}_j = \text{clip}\left(\frac{o_j - \mu_j}{\sqrt{\sigma_j^2 + \epsilon}}, -c, c\right)$$

Action repeat και χρονική εξομάλυνση δράσεων

Για να περιοριστούν πολύ συχνές εναλλαγές στην ταχύτητα και κυρίως στη γωνία διεύθυνσης, χρησιμοποιήθηκε action repeat = 2. Αυτό σημαίνει ότι ο TD3 υπολογίζει μία νέα δράση κάθε δύο βήματα του προσομοιωτή και η ίδια εντολή εφαρμόζεται διαδοχικά και στα δύο βήματα.

Επομένως, η συχνότητα με την οποία αλλάζουν οι εντολές ελέγχου μειώνεται στο μισό. Η τεχνική αυτή λειτουργεί ως μορφή χρονικής εξομάλυνσης, καθώς περιορίζει απότομες διαδοχικές αλλαγές του steering και μπορεί να οδηγήσει σε πιο συνεκτικές και λιγότερο ταλαντωτικές τροχιές για ένα car-like robot.

Παρότι η πολιτική λαμβάνει νέα απόφαση κάθε δύο simulator steps, το replay buffer συνεχίζει να αποθηκεύει κανονικές one-step transitions και ο TD3 διατηρεί δυνατότητα ενημέρωσης ανά φυσικό βήμα του περιβάλλοντος. Η ίδια τιμή action repeat χρησιμοποιείται και κατά την αξιολόγηση, ώστε να μην υπάρχει διαφορά μεταξύ training και deployment.

Χειρισμός του κόστους ασφαλείας

Το περιβάλλον παρέχει σε κάθε βήμα δύο διαφορετικά μεγέθη: το reward r_t που εκφράζει την πρόοδο προς τον στόχο, και το safety cost c_t που εκφράζει μη ασφαλείς αλληλεπιδράσεις, όπως επαφές με hazards, gremlins ή λανθασμένα buttons.

Στο nominal TD3 baseline χρησιμοποιείται:

$$r_t^{\text{train}} = r_t$$

δηλαδή $\lambda=0$. Στις safety-aware παραλλαγές, ο στόχος εκπαίδευσης τροποποιείται ως:

$$r_t^{\text{train}} = r_t - \lambda c_t$$

Το λ δεν μεταβάλλει το reward ή το cost που υπολογίζει το benchmark. Επηρεάζει αποκλειστικά το σήμα εκπαίδευσης με το οποίο ενημερώνονται οι critics και, έμμεσα, ο actor. Επομένως, η πολιτική δεν μαθαίνει απλώς να μεγιστοποιεί task reward, αλλά να μεγιστοποιεί ένα trade-off μεταξύ προόδου και ασφάλειας.

Μικρή τιμή λ δίνει προτεραιότητα στην επίτευξη του στόχου και μπορεί να οδηγήσει σε υψηλότερο reward με μεγαλύτερο cumulative cost. Μεγαλύτερη τιμή λ αυξάνει το κίνητρο αποφυγής, αλλά μπορεί να κάνει την πολιτική υπερσυντηρητική. Ειδικά στα πρώτα στάδια εκπαίδευσης, πολύ υψηλό λ μπορεί να οδηγήσει σε στάση, αργή κίνηση ή αποτυχία προσέγγισης του στόχου.

SAC

Ο Soft Actor-Critic (SAC) αποτελεί έναν off-policy actor-critic αλγόριθμο Reinforcement Learning για προβλήματα συνεχούς action space. Όπως και ο TD3, χρησιμοποιεί replay buffer, target networks και δύο ανεξάρτητα critic networks (Twin Critics) για τη βελτίωση της σταθερότητας της εκπαίδευσης. Η βασική διαφορά του SAC είναι ότι βασίζεται στη φιλοσοφία του Maximum Entropy Reinforcement Learning, σύμφωνα με την οποία ο agent δεν επιδιώκει μόνο τη μεγιστοποίηση της συνολικής ανταμοιβής, αλλά και τη διατήρηση υψηλής εντροπίας (entropy) στην πολιτική του.

Σε αντίθεση με τον TD3, όπου ο actor υλοποιεί μία ντετερμινιστική πολιτική, στον SAC ο actor υλοποιεί μία στοχαστική Gaussian πολιτική. Για κάθε s κατάσταση, το νευρωνικό δίκτυο υπολογίζει τις παραμέτρους μίας κανονικής κατανομής, δηλαδή τη μέση τιμή μ και την τυπική απόκλιση σ , από τις οποίες πραγματοποιείται δειγματοληψία της τελικής ενέργειας. Με τον τρόπο αυτό η εξερεύνηση προκύπτει φυσικά από την ίδια την πολιτική και δεν απαιτείται η προσθήκη εξωτερικού θορύβου στις ενέργειες, όπως συμβαίνει στον TD3.

Η πολιτική του SAC εκπαιδεύεται μεγιστοποιώντας την ακόλουθη συνάρτηση:

$$J(\pi) = \mathbb{E} \left[\sum_t r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot | s_t)) \right]$$

όπου $\mathcal{H}(\pi)$ είναι η εντροπία της πολιτικής και α η temperature parameter, η οποία καθορίζει την ισορροπία μεταξύ exploration και exploitation.

Επειδή η εκπαίδευση των νευρωνικών δικτύων πραγματοποιείται μέσω ελαχιστοποίησης μιας συνάρτησης κόστους, η παραπάνω αντικειμενική συνάρτηση διατυπώνεται ισοδύναμα ως:

$$L_{actor} = \mathbb{E}[\alpha \log \pi(a | s) - Q(s, a)]$$

Με την ελαχιστοποίηση της παραπάνω συνάρτησης, ο Actor εκπαιδεύεται ώστε να επιλέγει ενέργειες με υψηλή αναμενόμενη ανταμοιβή, διατηρώντας παράλληλα υψηλή εντροπία στην πολιτική.

Όπως και στον TD3, η εκτίμηση της value function πραγματοποιείται από δύο ανεξάρτητα critic networks. Η χρήση των Twin Critics περιορίζει το φαινόμενο του overestimation bias, ενώ κατά τον υπολογισμό της τιμής στόχου χρησιμοποιείται η μικρότερη από τις δύο εκτιμήσεις. Ωστόσο, σε αντίθεση με τον TD3, ο στόχος εκπαίδευσης περιλαμβάνει επιπλέον τον όρο εντροπίας:

$$y = r + \gamma(\min(Q'_1, Q'_2) - \alpha \log \pi(a' | s'))$$

Ο Critic ενημερώνεται ελαχιστοποιώντας το μέσο τετραγωνικό σφάλμα μεταξύ της εκτιμώμενης τιμής $Q(s, a)$ και της target value που υπολογίζεται από τη Soft Bellman Equation:

$$L_{critic} = (Q - y)^2$$

Ένα ακόμη χαρακτηριστικό του SAC είναι η αυτόματη προσαρμογή της παραμέτρου θερμοκρασίας α . Αντί να παραμένει σταθερή κατά τη διάρκεια της εκπαίδευσης, η τιμή της ενημερώνεται ώστε η εντροπία της πολιτικής να παραμένει κοντά σε μία προκαθορισμένη επιθυμητή τιμή (target entropy). Στην παρούσα υλοποίηση η target entropy υπολογίζεται ως:

$$\mathcal{H}_{target} = -\text{entropy multiplier} \cdot \text{action dimension}$$

επιτρέποντας τη ρύθμιση του επιπέδου εξερεύνησης μέσω της υπερπαραμέτρου entropy multiplier.

Τέλος, όπως και στον TD3, οι παράμετροι των target critics ενημερώνονται μέσω soft updates, ενώ σε κάθε επανάληψη της εκπαίδευσης πραγματοποιείται δειγματοληψία ενός batch από το replay buffer, ενημέρωση των critic networks, ενημέρωση του actor και προσαρμογή της παραμέτρου α .

Παράμετρος	Σύντομη λειτουργία / επίδραση
ENV_NAME	Επιλέγει το benchmark περιβάλλον.
AGENT_ID	Αναγνωριστικό του πειράματος και των αρχείων αποτελεσμάτων.
LOAD_MODEL	Φόρτωση προϋπάρχοντος μοντέλου για συνέχιση εκπαίδευσης ή fine-tuning.
LOAD_RESULTS_PATH	Φάκελος από τον οποίο φορτώνονται τα αποθηκευμένα αποτελέσματα (reward, cost, losses, alpha κ.λπ.) ώστε να συνεχιστεί ένα προηγούμενο πείραμα χωρίς απώλεια ιστορικού. Αν συνεχίζεται training με άλλες παραμετρους προτείνεται να παραμείνει "" ή None επειδή θα επηρεάσει το saving new best model, το οποίο γίνεται με βάση best_score (r-λc).
MAX_TIMESTEPS	Συνολικό πλήθος environment steps εκπαίδευσης.
START_TIMESTEPS	Αρχικά βήματα τυχαίας εξερεύνησης πριν ξεκινήσει η εκπαίδευση. Αν φορτωθεί μοντέλο ακολουθεί προηγούμενη πολιτική.
MAX_STEPS	Μέγιστη διάρκεια κάθε επεισοδίου.
ACTION_REPEAT	Κάθε δράση εφαρμόζεται για περισσότερα από ένα environment steps, εξομαλύνοντας την κίνηση.
REPLAY_BUFFER_SIZE	Μέγιστη χωρητικότητα του Replay Buffer.
BATCH_SIZE	Πλήθος μεταβάσεων ανά ενημέρωση των νευρωνικών δικτύων.
ACTOR_LR	Learning rate του Actor.
CRITIC_LR	Learning rate των Critic networks.
DISCOUNT (γ)	Βάρος μελλοντικής ανταμοιβής στο Bellman target. Ευνοεί μακροπρόθεσμη πρόοδο προς το σωστό button.
TAU (τ)	Συντελεστής Polyak averaging για τα Target Networks.
entropy_multiplier	Καθορίζει την target entropy που χρησιμοποιείται για την αυτόματη προσαρμογή του α .

COST_WEIGHT (λ)	Συντελεστής ποινής του safety cost στη διαμορφωμένη ανταμοιβή.
EVAL_FREQ	Συχνότητα αξιολόγησης της πολιτικής.
SAC_EVAL_EPISODES	Πλήθος επεισοδίων ανά αξιολόγηση.
SEED	Αρχικοποιεί τις ψευδοτυχαίες γεννήτριες, βελτιώνοντας την αναπαραγωγικότητα του πειράματος.

Action Repeat και χρονική εξομάλυνση

Και στην περίπτωση του SAC χρησιμοποιήθηκε Action Repeat ίσο με 2. Αυτό σημαίνει ότι κάθε ενέργεια που παράγεται από τον Actor εφαρμόζεται για δύο διαδοχικά βήματα του προσομοιωτή πριν ληφθεί νέα απόφαση.

Η επιλογή αυτή μειώνει τη συχνότητα μεταβολής των εντολών ελέγχου και λειτουργεί ως μορφή χρονικής εξομάλυνσης της κίνησης. Στο συγκεκριμένο περιβάλλον συνέβαλε στη μείωση των απότομων μεταβολών του steering και στην παραγωγή ομαλότερων τροχιών, χωρίς να αλλάζει ο τρόπος εκπαίδευσης του αλγορίθμου.

Χειρισμός του κόστους ασφαλείας

Όπως και στον TD3, το περιβάλλον παρέχει ανεξάρτητα το reward και το safety cost. Στο nominal SAC χρησιμοποιείται μόνο το reward, ενώ στις safety-aware εκτελέσεις το σήμα εκπαίδευσης τροποποιείται ως:

$$r^{train} = r - \lambda c$$

όπου η παράμετρος λ καθορίζει το trade-off μεταξύ επίτευξης του στόχου και αποφυγής μη ασφαλών ενεργειών.

Ρύθμιση της Target Entropy

Ένα από τα βασικά χαρακτηριστικά του SAC είναι η αυτόματη προσαρμογή της παραμέτρου θερμοκρασίας α , η οποία καθορίζει την ισορροπία μεταξύ εξερεύνησης (exploration) και εκμετάλλευσης (exploitation). Η τιμή της ενημερώνεται κατά τη

διάρκεια της εκπαίδευσης ώστε η εντροπία της πολιτικής να παραμένει κοντά σε μία προκαθορισμένη επιθυμητή τιμή (target entropy).

Στην παρούσα υλοποίηση, η target entropy υπολογίζεται ως:

$$\mathcal{H}_{target} = -\text{entropy multiplier} \cdot \text{action dimension}$$

όπου η υπερπαράμετρος entropy multiplier καθορίζει την επιθυμητή εντροπία της πολιτικής. Μεγαλύτερες τιμές οδηγούν σε μεγαλύτερη εξερεύνηση του περιβάλλοντος, ενώ μικρότερες τιμές ευνοούν πιο ντετερμινιστική συμπεριφορά. Κατά την εκπαίδευση χρησιμοποιήθηκε κυρίως μία σταθερή τιμή της παραμέτρου, η οποία επιλέχθηκε έπειτα από περιορισμένο πειραματισμό ώστε να επιτυγχάνεται σταθερή συμπεριφορά του αλγορίθμου.

Πειραματική διαδικασία

Ρυθμίσεις εκπαίδευσης στον TD3

1. Navigation baseline χωρίς ποινή ασφάλειας

Αρχική εκπαίδευση TD3 με $\lambda = 0$ και action repeat = 2.

Παράμετρος	Τιμή
ENV_ID	SafetyRacecarButton2-v0
RUN_NAME	button2_td3_baseline_half_action_repeat_termination
ACTION_REPEAT	2
UPDATES_PER_ACTION_DECISION	2
GOAL_TERMINATION	True
SEED	42
LOAD_FROM	none
SOURCE_RUN_NAME	button2_td3_baseline_half_action_repeat_termination
SOURCE_POLICY_FILE	last_model.pt

TOTAL_STEPS	700,000
RANDOM_STEPS	100,000
POLICY_REFILL_STEPS	30,000
BUFFER_SIZE	500,000
BATCH_SIZE	256
EXPLORATION_NOISE	0.10
EVALUATE_EVERY	25,000
EVALUATION_EPISODES	10
SAVE_FULL_CHECKPOINT_EVERY	50,000
OBS_NORMALIZER_CLIP	5.0
USE_TENSORBOARD	True
TENSORBOARD_EVERY	1,000
COST_PENALTY (λ)	0.0
BEST_SELECTION_COST_WEIGHT	0.0
LEARNING_RATE	5e-5
DISCOUNT (γ)	0.99
TAU (τ)	0.005
POLICY_NOISE	0.2
NOISE_CLIP	0.5
POLICY_DELAY	2

2. Συνέχιση του navigation baseline με χαμηλότερο learning rate

Exact continuation του ίδιου run από το latest_full checkpoint.

Παράμετρος	Τιμή
ENV_ID	SafetyRacecarButton2-v0
RUN_NAME	button2_td3_baseline_half_action_repeat_termination
ACTION_REPEAT	2

UPDATES_PER_ACTION_DECISION	2
GOAL_TERMINATION	True
SEED	42
LOAD_FROM	latest
SOURCE_RUN_NAME	button2_td3_baseline_half_action_repeat_termination
SOURCE_POLICY_FILE	last_model.pt
TOTAL_STEPS	1,200,000
RANDOM_STEPS	0
POLICY_REFILL_STEPS	30,000
BUFFER_SIZE	500,000
BATCH_SIZE	256
EXPLORATION_NOISE	0.10
EVALUATE EVERY	25,000
EVALUATION_EPISODES	10
SAVE_FULL_CHECKPOINT EVERY	50,000
OBS_NORMALIZER_CLIP	5.0
USE_TENSORBOARD	True
TENSORBOARD EVERY	1,000
COST_PENALTY (λ)	0.0
BEST_SELECTION_COST_WEIGHT	0.0
LEARNING_RATE	3e-5
DISCOUNT (γ)	0.99
TAU (τ)	0.005
POLICY_NOISE	0.2
NOISE_CLIP	0.5
POLICY_DELAY	2



3. Safety fine-tuning branch $\mu \epsilon \lambda = 0.005$

Νέο branch από το navigation baseline με fresh replay-buffer refill.

Παράμετρος	Τιμή
ENV_ID	SafetyRacecarButton2-v0
RUN_NAME	button2_td3_baseline_half_action_repeat_termination_continue_cost_0.005
ACTION_REPEAT	2
UPDATES_PER_ACTION_DECISION	2
GOAL_TERMINATION	True
SEED	42
LOAD_FROM	branch
SOURCE_RUN_NAME	button2_td3_baseline_half_action_repeat_termination
SOURCE_POLICY_FILE	last_model.pt

TOTAL_STEPS	300,000
RANDOM_STEPS	0
POLICY_REFILL_STEPS	50,000
BUFFER_SIZE	500,000
BATCH_SIZE	256
EXPLORATION_NOISE	0.08
EVALUATE_EVERY	25,000
EVALUATION_EPISODES	10
SAVE_FULL_CHECKPOINT_EVERY	50,000
OBS_NORMALIZER_CLIP	5.0
USE_TENSORBOARD	True
TENSORBOARD_EVERY	1,000
COST_PENALTY (λ)	0.005
BEST_SELECTION_COST_WEIGHT	0.005
LEARNING_RATE	3e-5
DISCOUNT (γ)	0.99
TAU (τ)	0.005
POLICY_NOISE	0.2
NOISE_CLIP	0.5
POLICY_DELAY	2

4. Συνέχιση του branch με $\lambda = 0.005$

Exact continuation του safety branch με αυξημένο exploration noise.

Παράμετρος	Τιμή
ENV_ID	SafetyRacecarButton2-v0
RUN_NAME	button2_td3_baseline_half_action_repeat_termination_continue_cost_0.005
ACTION_REPEAT	2
UPDATES_PER_ACTION_DECISION	2
GOAL_TERMINATION	True
SEED	42
LOAD_FROM	latest

SOURCE_RUN_NAME	button2_td3_baseline_half_action_repeat_termination_continue_cost_0.005
SOURCE_POLICY_FILE	last_model.pt
TOTAL_STEPS	800,000
RANDOM_STEPS	0
POLICY_REFILL_STEPS	50,000
BUFFER_SIZE	500,000
BATCH_SIZE	256
EXPLORATION_NOISE	0.10
EVALUATE_EVERY	25,000
EVALUATION_EPISODES	10
SAVE_FULL_CHECKPOINT_EVERY	50,000
OBS_NORMALIZER_CLIP	5.0
USE_TENSORBOARD	True
TENSORBOARD_EVERY	1,000
COST_PENALTY (λ)	0.005
BEST_SELECTION_COST_WEIGHT	0.005
LEARNING_RATE	3e-5
DISCOUNT (γ)	0.99
TAU (τ)	0.005
POLICY_NOISE	0.2
NOISE_CLIP	0.5
POLICY_DELAY	2




5. Ισχυρότερο safety fine-tuning branch με $\lambda = 0.01$

Νέο branch από την τελευταία policy του branch $\lambda = 0.005$.

Παράμετρος	Τιμή
ENV_ID	SafetyRacecarButton2-v0
RUN_NAME	button2_td3_baseline_half_action_repeat_termination_continue_cost_0.01
ACTION_REPEAT	2
UPDATES_PER_ACTION_DECISION	2
GOAL_TERMINATION	True
SEED	42
LOAD_FROM	branch
SOURCE_RUN_NAME	button2_td3_baseline_half_action_repeat_termination_continue_cost_0.005
SOURCE_POLICY_FILE	last_model.pt

TOTAL_STEPS	800,000
RANDOM_STEPS	0
POLICY_REFILL_STEPS	50,000
BUFFER_SIZE	500,000
BATCH_SIZE	256
EXPLORATION_NOISE	0.10
EVALUATE_EVERY	25,000
EVALUATION_EPISODES	10
SAVE_FULL_CHECKPOINT_EVERY	50,000
OBS_NORMALIZER_CLIP	5.0
USE_TENSORBOARD	True
TENSORBOARD_EVERY	1,000
COST_PENALTY (λ)	0.01
BEST_SELECTION_COST_WEIGHT	0.005
LEARNING_RATE	3e-5
DISCOUNT (γ)	0.99
TAU (τ)	0.005
POLICY_NOISE	0.2
NOISE_CLIP	0.5
POLICY_DELAY	2



6. Branch με $\lambda = 0.01$ και αυξημένο exploration noise

Νέο branch από το best model της εκτέλεσης $\lambda = 0.01$. Ο λόγος που αυξήσαμε κι άλλο το exploration noise για αυτό το run, είναι ότι παρατηρήθηκε ότι σε μερικά runs, ο agent κολλούσε για πολύ ώρα πάνω στα λάθος buttons, με αποτέλεσμα να αυξάνεται πολύ το κόστος. Οπότε έπρεπε βάζοντας exploration noise μεγαλύτερο, να τον ωθήσουμε να βρει actions που θα τον κάνουν να προσαρμόσει την πολιτική του.

Παράμετρος	Τιμή
ENV_ID	SafetyRacecarButton2-v0
RUN_NAME	button2_td3_baseline_half_action_repeat_termination_continue_cost_0.01_exploration_noise_0.12
ACTION_REPEAT	2
UPDATES_PER_ACTION_DECISION	2
GOAL_TERMINATION	True
SEED	42
LOAD_FROM	branch

SOURCE_RUN_NAME	button2_td3_baseline_half_action_repeat_termination_continue_cost_0.01
SOURCE_POLICY_FILE	best_model.pt
TOTAL_STEPS	800,000
RANDOM_STEPS	0
POLICY_REFILL_STEPS	50,000
BUFFER_SIZE	500,000
BATCH_SIZE	256
EXPLORATION_NOISE	0.12
EVALUATE_EVERY	25,000
EVALUATION_EPISODES	10
SAVE_FULL_CHECKPOINT_EVERY	50,000
OBS_NORMALIZER_CLIP	5.0
USE_TENSORBOARD	True
TENSORBOARD_EVERY	1,000
COST_PENALTY (λ)	0.01
BEST_SELECTION_COST_WEIGHT	0.005
LEARNING_RATE	3e-5
DISCOUNT (γ)	0.99
TAU (τ)	0.005
POLICY_NOISE	0.2
NOISE_CLIP	0.5
POLICY_DELAY	2




7. Τελικό safety branch με $\lambda = 0.02$

Active final branch από την τελευταία policy του branch με exploration noise = 0.12.


Παράμετρος	Τιμή
ENV_ID	SafetyRacecarButton2-v0
RUN_NAME	button2_td3_baseline_half_action_repeat_termination_continue_cost_0.02
ACTION_REPEAT	2
UPDATES_PER_ACTION_DECISION	2
GOAL_TERMINATION	True
SEED	42
LOAD_FROM	branch
SOURCE_RUN_NAME	button2_td3_baseline_half_action_repeat_termination_continue_cost_0.01_exploration_noise_0.12
SOURCE_POLICY_FILE	last_model.pt

TOTAL_STEPS	1,000,000
RANDOM_STEPS	0
POLICY_REFILL_STEPS	50,000
BUFFER_SIZE	500,000
BATCH_SIZE	256
EXPLORATION_NOISE	0.10
EVALUATE_EVERY	25,000
EVALUATION_EPISODES	10
SAVE_FULL_CHECKPOINT_EVERY	50,000
OBS_NORMALIZER_CLIP	5.0
USE_TENSORBOARD	True
TENSORBOARD_EVERY	1,000
COST_PENALTY (λ)	0.02
BEST_SELECTION_COST_WEIGHT	0.005
LEARNING_RATE	3e-5
DISCOUNT (γ)	0.99
TAU (τ)	0.005
POLICY_NOISE	0.2
NOISE_CLIP	0.5
POLICY_DELAY	2



Ρυθμίσεις εκπαίδευσης στον SAC

1. Target Entropy Optimization



Τα αποτελέσματα αξιολόγησης του SAC με $\lambda = 0.02$ για τρεις διαφορετικές τιμές του entropy multiplier (0.1, 1, 10) παρουσιάζονται στα παρακάτω διαγράμματα.

Ο agent με `entropy_multiplier = 1` επιτυγχάνει το υψηλότερο reward (~6.7) και score (~6.2), ενώ παράλληλα διατηρεί σχετικά χαμηλό cost (~265). Αυτό υποδηλώνει ότι η τιμή αυτή επιτυγχάνει έναν καλό συμβιβασμό μεταξύ exploration και exploitation, επιτρέποντας στον agent να εντοπίζει αποδοτικά το σωστό κουμπί χωρίς υπερβολικό κίνδυνο.

Ο agent με `entropy_multiplier = 0.1` εμφανίζει μέτριο reward (~4.9) και score (~4.3), με το υψηλότερο cost (~282) από τους τρεις. Η χαμηλή εντροπία οδηγεί σε πιο ντετερμινιστική συμπεριφορά, η οποία φαίνεται να μην αρκεί για να αποφύγει ο agent τις μη ασφαλείς αλληλεπιδράσεις.

Ο agent με `entropy_multiplier = 10` παρουσιάζει το χαμηλότερο reward (~2.3) και score (~1.9), αλλά και το χαμηλότερο cost (~200). Η υπερβολική εντροπία οδηγεί σε πολύ τυχαία συμπεριφορά, με αποτέλεσμα ο agent να αδυνατεί να συγκλίνει σε αποδοτική πολιτική — παρόλο που αποφεύγει περισσότερες συγκρούσεις, αυτό οφείλεται κυρίως στην έλλειψη στοχευμένης κίνησης και όχι σε ουσιαστική εκμάθηση ασφαλούς πλοήγησης.





Συνολικά, τα αποτελέσματα επιβεβαιώνουν ότι η ρύθμιση της target entropy αποτελεί κρίσιμη υπερπαράμετρο για τον SAC στο συγκεκριμένο περιβάλλον.

Βάσει των παραπάνω αποτελεσμάτων, επιλέχθηκε ο agent με `entropy_multiplier = 1` για περαιτέρω αξιολόγηση, καθώς επέτυχε την καλύτερη ισορροπία μεταξύ reward και cost. Συγκεκριμένα, ανέδειξε το υψηλότερο score και reward μεταξύ των τριών παραλλαγών, διατηρώντας παράλληλα αποδεκτό επίπεδο safety cost.

2. Baseline με episode length 1000 actions, $\lambda = 0$ και action repeat 1

Ένα baseline με υλοποίηση SAC για μηδενικό λ . Φαίνεται η εκπαίδευση του μοντέλου, αλλά και η αύξηση του κόστους καθώς δεν επηρεάζει την εκπαίδευση για $\lambda = 0$.

```
train_1(MAX_TIMESTEPS = int(2e6),
        START_TIMESTEPS = int(2e5),
        LOAD_MODEL = None,
        LOAD_RESULTS_PATH = None,
        ENV_NAME = "SafetyRacecarButton2-v0",
        MAX_STEPS = 1000,
        BATCH_SIZE = 256,
        EVAL_FREQ = 25000,
        SAC_EVAL_EPISODES = 30,
        GAMMA = 0.99,
        TAU = 0.005,
        ACTOR_LR = 1e-4,
        CRITIC_LR = 1e-4,
        entropy_multiplier = 1.0,
        COST_WEIGHT = 0.000,
        TURNING_WEIGHT = 0.0,
        SEED = 0,
        SAC_MODEL_PATH = "models/",
        AGENT_ID = "sac_baseline",
    )
```







3. Μείωση μήκους επεισοδίου σε 500 actions και action repeat 2

i) Για $\lambda=0$ (το evaluation γίνεται για 1000 episode length)





Η μείωση του μήκους του κάθε επεισοδίου σε συνδυασμό με το action repeat (για μεγαλύτερες τιμές από 2 επηρεάζεται αρνητικά η συμπεριφορά) διευκολύνει σημαντικά την εκμάθηση του μοντέλου καθώς τα επεισόδια για ίδιο αριθμό συνολικών actions στο training αυξάνονται. Το model βλέπει περισσότερες καταστάσεις και κάνει λιγότερες κινήσεις ανά επεισόδια. Φαίνεται παρακάτω, καθώς το reward έχει διπλασιαστεί για τα μισά max action steps.

```
train_2(MAX_Timesteps = int(1e6),
        START_Timesteps = int(5e4),
        LOAD_MODEL = None,
        LOAD_RESULTS_PATH = None,
        ENV_NAME = "SafetyRacecarButton2-v0",
        MAX_STEPS = 500,
        BATCH_SIZE = 256,
        REPLAY_BUFFER_SIZE = int(3e5),
        EVAL_FREQ = 25000,
        SAC_EVAL_EPISODES = 30,
        GAMMA = 0.99,
        TAU = 0.005,
        ACTOR_LR = 5e-5,
        CRITIC_LR = 5e-5,
        entropy_multiplier = 1.0,
        COST_WEIGHT = 0.0,
        TURNING_WEIGHT = 0,
        ACTION_REPEAT = 2,
        SEED = 0,
        SAC_MODEL_PATH = "models/",
        AGENT_ID = "sac_ms_500_ar2_c0_em1_mt1e6_st_5e4",
        )
```

ii) $\lambda = 0.005$ (το evaluation είναι για 500 episode length)

```
train_2(MAX_TIMESTEPS = int(1e6),
        START_TIMESTEPS = int(5e4),
        LOAD_MODEL = "sac_ms_500_ar2_c0_em1_mt1e6_st_5e4_best",
        LOAD_RESULTS_PATH = None,
        ENV_NAME = "SafetyRacecarButton2-v0",
        MAX_STEPS = 500,
        BATCH_SIZE = 256,
        REPLAY_BUFFER_SIZE = int(3e5),
        EVAL_FREQ = 25000,
        SAC_EVAL_EPISODES = 30,
        GAMMA = 0.99,
        TAU = 0.005,
        ACTOR_LR = 5e-5,
        CRITIC_LR = 5e-5,
        entropy_multiplier = 1.0,
        COST_WEIGHT = 0.005,
        TURNING_WEIGHT = 0,
        ACTION_REPEAT = 2,
        SEED = 0,
        SAC_MODEL_PATH = "models/",
        AGENT_ID = "sac_ms_500_ar2_c0toc005_em1_mt1e6_st_5e4",
        )
```







Έχει αρχίσει να αντιλαμβάνεται τα εμπόδια με το κόστος να είναι 0.005 αλλά δεν καταφέρνει να τα αποφύγει. Ωστόσο αρκεί για να μάθει καλύτερες τροχιές και να μην συγκρούεται με λανθασμένα κουμπιά.

4. Τερματισμός επεισοδίου στο πρώτο σωστό κουμπί

i) $\lambda = 0$ και action repeat 2

Εφαρμόζοντας τερματισμό του επεισοδίου όταν βρεθεί το πρώτο κουμπί, κάνει ακόμα πιο αποτελεσματικό το training. Στα αρχικά βήματα δεν υπάρχει διαφορά αλλά μόλις αρχίσει ο agent να βρίσκει τα κουμπιά το μήκος των επεισοδίων μειώνεται δραματικά (από 500 σε 100 actions, με ορισμένα training episodes α φτάνουν και τα 30). Παρακάτω φαίνεται και το success rate που αντιπροσωπεύει πόσες φορές φτάνει σε σωστό κουμπί.

```
train_5(MAX_TIMESTEPS = int(7e5),
        START_TIMESTEPS = int(5e4),
        LOAD_MODEL = None,
        LOAD_RESULTS_PATH = None,
        ENV_NAME = "SafetyRacecarButton2-v0",
        MAX_STEPS = 500,
        BATCH_SIZE = 256,
        REPLAY_BUFFER_SIZE = int(3e5),
        EVAL_FREQ = 10000,
        SAC_EVAL_EPISODES = 30,
        GAMMA = 0.99,
        TAU = 0.005,
        ACTOR_LR = 5e-5,
        CRITIC_LR = 5e-5,
        entropy_multiplier = 1.0,
        COST_WEIGHT = 0.0,
        TURNING_WEIGHT = 0,
        ACTION_REPEAT = 2,
        SEED = 0,
        SAC_MODEL_PATH = "models/",
        AGENT_ID = "sac_single_B_ar2_c0_em1_rbs3e5_st5e4_mt1e6",
        )
```







ii) $\lambda = 0.05$

```

train_5(MAX_TIMESTEPS = int(7e5),
        START_TIMESTEPS = int(5e4),
        LOAD_MODEL = "sac_single_B_ar2_c0_em1_rbs3e5_st5e4_mt1e6_best",
        LOAD_RESULTS_PATH = None,
        ENV_NAME = "SafetyRacecarButton2-v0",
        MAX_STEPS = 500,
        BATCH_SIZE = 256,
        REPLAY_BUFFER_SIZE = int(3e5),
        EVAL_FREQ = 10000,
        SAC_EVAL_EPISODES = 30,
        GAMMA = 0.99,
        TAU = 0.005,
        ACTOR_LR = 5e-5,
        CRITIC_LR = 5e-5,
        entropy_multiplier = 1.0,
        COST_WEIGHT = 0.05,
        TURNING_WEIGHT = 0,
        ACTION_REPEAT = 2,
        SEED = 0,
        SAC_MODEL_PATH = "models/",
        AGENT_ID = "sac_single_B_ar2_c0toc05_em1_rbs3e5_st5e4_mt1e6", #
    )

```




Με την αύξηση του λ σε 0.05 παρατηρείται σημαντική πτώση στο μέσο κόστος, συμβολίζοντας μια αρχή σε αποφυγή εμποδίων. Ωστόσο το μέσο κόστος 8 είναι ακόμα υψηλό εφόσον το επεισόδιο τερματίζει στο πρώτο κουμπί προκαλώντας πολύ σύντομες τροχιές.

iii) $\lambda = 0.1$

```


train_5(MAX_TIMESTEPS = int(1e6),
        START_TIMESTEPS = int(5e4),
        LOAD_MODEL = "sac_single_B_ar2_c0toc05_em1_rbs3e5_st5e4_mt1e6_best",
        LOAD_RESULTS_PATH = None,
        ENV_NAME = "SafetyRacecarButton2-v0",
        MAX_STEPS = 500,
        BATCH_SIZE = 256,
        REPLAY_BUFFER_SIZE = int(3e5),
        EVAL_FREQ = 10000,
        SAC_EVAL_EPISODES = 30,
        GAMMA = 0.99,
        TAU = 0.005,
        ACTOR_LR = 5e-5,
        CRITIC_LR = 5e-5,
        entropy_multiplier = 1.0,
        COST_WEIGHT = 0.1,
        TURNING_WEIGHT = 0,
        ACTION_REPEAT = 2,
        SEED = 0,
        SAC_MODEL_PATH = "models/",
        AGENT_ID = "sac_single_B_ar2_c05toc1_em1_rbs3e5_st5e4_mt1e6",
        )

```



Το κόστος 0.1 αποδεικνύεται πολύ υψηλό. Το μέσος κόστος δεν μειώνεται αλλά το success rate μειώνεται από το 96% του $\lambda = 0.05$. Η πολιτική πλέον προτιμάει σε αρκετές καταστάσεις να μην προχωρήσει ο agent για να μην αυξηθεί το κόστος.

5.1 Σύγκριση αποτελεσμάτων



Η σύγκριση των μεθόδων πρέπει να ερμηνευθεί λαμβάνοντας υπόψη ορισμένες σημαντικές διαφορές στις διαδικασίες εκπαίδευσης. Αρχικά, οι TD3 agents χρησιμοποιούν online κανονικοποίηση των παρατηρήσεων (observation normalization), ενώ οι SAC agents εκπαιδεύτηκαν απευθείας πάνω στις ακατέργαστες παρατηρήσεις του περιβάλλοντος. Η κανονικοποίηση μπορεί να βελτιώσει τη σταθερότητα της εκπαίδευσης και πιθανώς συνέβαλε στην καλύτερη και πιο συνεπή απόδοση των TD3 μοντέλων.

Επιπλέον, όλα τα μοντέλα, με εξαίρεση τις παραλλαγές SAC_SB, εκπαιδεύτηκαν χωρίς goal termination, δηλαδή το επεισόδιο συνέχιζε ακόμη και μετά την επιτυχή

ενεργοποίηση του σωστού κουμπιού. Αντίθετα, στις παραλλαγές SAC_SB το επεισόδιο τερματιζόταν αμέσως μετά την επίτευξη του στόχου. Η επιλογή αυτή μειώνει τόσο τη συσσωρευμένη ανταμοιβή όσο και το συνολικό κόστος μετά την επίτευξη του στόχου, αλλά επηρεάζει και τη διαδικασία εκπαίδευσης. Συγκεκριμένα, τα μικρότερα επεισόδια οδηγούν σε διαφορετική κατανομή εμπειριών και σε λιγότερες παρατηρήσεις καταστάσεων που εμφανίζονται μετά την επίτευξη του στόχου για το ίδιο συνολικό training budget σε environment steps. Επομένως, οι διαφορές στην απόδοση των SAC_SB μοντέλων δεν μπορούν να αποδοθούν αποκλειστικά στη συνάρτηση κόστους, αλλά και στη διαφορετική δυναμική εκπαίδευσης που εισάγει ο πρόωρος τερματισμός των επεισοδίων.

Η παραλλαγή SAC_0.01_em_dec-3 διαφοροποιείται περαιτέρω από τα υπόλοιπα μοντέλα, καθώς χρησιμοποιεί entropy scheduling. Συγκεκριμένα, ο target entropy multiplier μειώνεται προοδευτικά από 3 σε 1 κατά τη διάρκεια της εκπαίδευσης. Η στρατηγική αυτή επιτρέπει αρχικά μεγαλύτερη εξερεύνηση του περιβάλλοντος και σταδιακά οδηγεί σε πιο ντετερμινιστική και συντηρητική συμπεριφορά. Το συγκεκριμένο μοντέλο εκπαιδεύτηκε επίσης με action repeat ίσο με 1 αντί για 2. Επομένως, οι διαφορές στην απόδοσή του δεν μπορούν να αποδοθούν αποκλειστικά στο entropy scheduling, καθώς η αλλαγή του action repeat αποτελεί έναν επιπλέον διαφοροποιητικό παράγοντα του πειραματικού πρωτοκόλλου.

Συνεπώς, οι διαφορές που παρατηρούνται μεταξύ των μοντέλων δεν οφείλονται αποκλειστικά στον ίδιο τον αλγόριθμο RL ή στην τιμή της ποινής κόστους λ , αλλά και σε δευτερεύουσες σχεδιαστικές επιλογές, όπως η κανονικοποίηση των παρατηρήσεων, η χρήση goal termination, η ρύθμιση της εντροπίας και η επιλογή του action repeat.

Τέλος, τα αποτελέσματα των baseline μεθόδων παρέχουν ένα χρήσιμο σημείο αναφοράς για την αξιολόγηση των αλγορίθμων RL. Η τυχαία πολιτική (Random Policy) παρουσιάζει σχεδόν μηδενική ανταμοιβή και υψηλή διακύμανση στο κόστος, επιβεβαιώνοντας ότι το περιβάλλον δεν μπορεί να επιλυθεί χωρίς εκμάθηση ή ενσωμάτωση γνώσης του προβλήματος. Αντίθετα, ο χειροποίητος controller (Rule-Based Controller) επιτυγχάνει σημαντικά καλύτερη απόδοση, γεγονός που δείχνει ότι απλοί ευρετικοί κανόνες είναι ικανοί να επιλύσουν εν μέρει την εργασία. Ωστόσο, το υψηλό κόστος που παρουσιάζει υποδηλώνει ότι οι κανόνες αυτοί δεν επαρκούν για ασφαλή πλοήγηση και αποφυγή επικίνδυνων καταστάσεων. Συνεπώς, οι μέθοδοι RL καταφέρνουν είτε να ξεπεράσουν τον χειροποίητο controller ως προς την ανταμοιβή είτε να επιτύχουν καλύτερο συμβιβασμό μεταξύ απόδοσης και ασφάλειας.

Βιβλιογραφία

- [1] K. Chatzilygeroudis, K. Asimakopoulos, L. Printzios, "Intelligent Control: 2025-2026 Projects", Project 1: Safe Mobile Robot Button Navigation, 17 May 2026.
- [2] S. Fujimoto, H. van Hoof, D. Meger, "Addressing Function Approximation Error in Actor-Critic Methods", Proceedings of ICML, 2018. (TD3).
- [3] Safety-Gymnasium Documentation, "Button Environments" και "Racecar Agent".
- [4] A. Ray, J. Achiam, D. Amodei, "Benchmarking Safe Exploration in Deep Reinforcement Learning", 2019.
- [5] J. García, F. Fernández, "A Comprehensive Survey on Safe Reinforcement Learning", Journal of Machine Learning Research, 2015.
- [6] A. Goida, "Data Series Normalization Techniques", Binary Notes, Medium, 24 Dec. 2024. (Z-score normalization and feature scaling).
- [7] J. Gryczka, "TD3 tutorial and implementation", Medium, 12 Dec. 2024. (TD3 implementation overview).
- [8] <https://github.com/haarnoja/sac>
- [9] <https://arxiv.org/abs/1812.05905>
- [10] https://spinningup.openai.com/en/latest/algorithms/sac.html?utm_source=chatgpt.com
- [11] <https://stable-baselines3.readthedocs.io/en/master/modules/sac.html>
- [12] <https://medium.com/@jiawei.kong/reinforcement-learning-tutorial-soft-actor-critic-sac-f0a097b328c3>
- [13] <https://www.geeksforgeeks.org/deep-learning/soft-actor-critic-reinforcement-learning-algorithm/>
- [14] T. F. Chan, G. H. Golub and R. J. LeVeque, "Algorithms for Computing the Sample Variance: Analysis and Recommendations," The American Statistician, vol. 37, no. 3, pp. 242–247, 1983, doi: 10.1080/00031305.1983.10483115.
- [15] B. P. Welford, "Note on a Method for Calculating Corrected Sums of Squares and Products," Technometrics, vol. 4, no. 3, pp. 419–420, 1962, doi: 10.1080/00401706.1962.10490022.